

# ANÁLISIS DE DATOS PARA LA TOMA DE DECISIONES

## CLASE 3

CHRISTIAN ARAYA

INSTITUTO DE ESTADÍSTICA  
PUCV

MARZO 2020



# **PARÉNTESIS: ELEMENTOS DE PROBABILIDAD**

## Introducción

- Sea  $E$  un experimento aleatorio,  $\Omega$  el espacio muestral asociado. Se define una variable aleatoria ( $X$ ) como una función real, es decir:  $X : \Omega \rightarrow \mathbb{R}$ , tal que  $\omega \rightarrow X(\omega) = x$ .
- Conceptualmente, lo que está haciendo la variable aleatoria es identificar un **aspecto numérico** de interés en un experimento aleatorio.
- **Ejemplos:** número de personas que ingresa a una estación de metro entre las 7:30 y 8:15 am; número de caras obtenidas al lanzar una moneda 300 veces; cantidad de alumnos del curso que están de cumpleaños el día 19 de abril.

## Conceptos importantes

- Llamaremos  $R_X$  al recorrido de la función  $X$  (variable aleatoria), es decir, representa el subconjunto de  $\mathbb{R}$  donde la variable toma sus valores.
- Si  $R_X$  es numerable, se dice que la variable aleatoria es discreta; si  $R_X$  es no numerable, se trata de una variable aleatoria continua.
- **Ejemplo:** supongamos que el experimento  $E$  es lanzar una moneda perfecta dos veces. Ya sabemos que el espacio muestral corresponde a:  
 $\Omega = \{(C,C)(C,S)(S,C)(S,S)\}$
- Si definimos  $X$  : número de sellos en los dos lanzamientos, entonces la v.a. toma los siguientes valores:
  - $X(C, C) = 0$
  - $X(C, S) = 1$
  - $X(S, C) = 1$
  - $X(S, S) = 2$

## Conceptos importantes

- Si definimos  $X$  : número de sellos en los dos lanzamientos, entonces la v.a. toma los siguientes valores:
- $X(C, C) = 0$
- $X(C, S) = 1$
- $X(S, C) = 1$
- $X(S, S) = 2$
- Notar que la función no es inyectiva.
- En este caso, el espacio numérico (recorrido) de  $X$  es:  $R_X = \{0,1,2\}$

# ESTADÍSTICOS

## Introducción

- En adelante, trabajaremos con una colección de variables aleatorias que llamaremos muestra:  $Y_1, \dots, Y_n$
- Esta muestra provendrá de una población de interés. Las variables aleatorias serán independientes e idénticamente distribuidas (tendrán la misma distribución).
- Algunas funciones de las variables aleatorias son utilizadas para estimar parámetros de la población, los que desconocemos generalmente.
- Por ejemplo, supongamos que queremos estimar la media de la población,  $\mu$ . Si tenemos  $n$  valores para las variables aleatorias:  $y_1, \dots, y_n$ , suena razonable que  $\mu$  sea estimado a partir de:  $\bar{Y} = \sum_{i=1}^n \frac{1}{n} y_i$

## Estadístico

- $\bar{Y} = \sum_{i=1}^n \frac{1}{n} y_i$  es una función de la muestra (depende sólo de los valores observados de las variables aleatorias y de la constante  $n$ ).
- Se define **estadístico** como cualquier función de la muestra (las variables aleatorias observables) y algunas constantes conocidas.
- Otros ejemplos son:  $S$  y  $S^2$ ;  $\max(Y_1, \dots, Y_n) = Y_{(n)}$ ;  $\min(Y_1, \dots, Y_n) = Y_{(1)}$ ; el rango  $Y_{(n)} - Y_{(1)}$ .
- Los estadísticos se usan para hacer **inferencia** sobre parámetros que se desconocen en la población y, como son una función de variables aleatorias, también son variables aleatorias.
- Los estadísticos, a partir de lo anterior, tienen distribución de probabilidades (sus **distribuciones asociadas al muestreo**).



## Distribuciones relacionadas con la dist. Normal

- Sea  $Y_1, \dots, Y_n$  una muestra aleatoria de tamaño  $n$  de una **distribución Normal** con una media  $\mu$  y varianza  $\sigma^2$ .
- Se define la media muestral como:  $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$
- Sabemos que  $\bar{Y}$  se distribuye Normal también, con  $\mu_{\bar{Y}} = \mu$  y  $\sigma_{\bar{Y}}^2 = \sigma^2/n$
- De aquí se deriva que  $Z = \frac{\bar{Y} - \mu_{\bar{Y}}}{\sigma_{\bar{Y}}} = \sqrt{n} \cdot \left( \frac{\bar{Y} - \mu}{\sigma} \right)$  sigue una **distribución Normal Estándar**.

## Ejemplo 1)

- Una máquina embotelladora puede ser regulada de modo que proporcione en promedio  $\mu$  ml por botella de jugo que llena. Se ha observado que la cantidad de líquido que entrega la máquina sigue una distribución Normal, con  $\sigma = 1$  ml. Una muestra de  $n = 9$  botellas se selecciona al azar de una partida que la máquina ha embotellado en un día y se mide el contenido de cada una. Encuentre la probabilidad de que el promedio de la muestra tenga una diferencia de a lo más 0,3 con respecto a la media de la población  $\mu$  para el proceso de embotellado en estudio.


## Ejemplo 2)

- Una máquina embotelladora puede ser regulada de modo que proporciona en promedio  $\mu$  ml por botella de jugo que llena. Se ha observado que la cantidad de líquido que entrega la máquina sigue una distribución Normal, con  $\sigma = 1$  ml. Una muestra de  $n = 9$  botellas se selecciona al azar de una partida que la máquina ha embotellado en un día y se mide el contenido de cada una. Encuentre la probabilidad de que el promedio de la muestra tenga una diferencia de a lo más 0,3 con respecto a la media de la población  $\mu$  para el proceso de embotellado en estudio.
- Cuál debe ser el tamaño muestral que se requiere considerar si se busca que  $\bar{Y}$  tenga una diferencia de 0,3 con respecto a  $\mu$ , con probabilidad 0,95.


$\chi^2$

- Sea  $Y_1, \dots, Y_n$  una muestra aleatoria de tamaño  $n$  de una **distribución Normal** con una media  $\mu$  y varianza  $\sigma^2$ .
- Sabemos que  $Z_i = (Y_i - \mu)/\sigma$ , con  $i$  entre 1 y  $n$ , son independientes ( $Y_i$  lo son) y siguen una **distribución Normal Estándar**.
- Luego:  $\sum_{i=1}^n Z_i^2$  tiene una distribución  $\chi^2$  con  **$n$  grados de libertad**, siendo  $n$  el parámetro para esta distribución.
- A diferencia de la distribución Normal, en esta distribución se observa un nivel de asimetría vinculado al valor de  $n$ .

**df1**



**df20**



## Uso de Distribución $\chi^2$

- Sea  $Y_1, \dots, Y_n$  una muestra aleatoria de tamaño  $n$  de una **distribución Normal** con una media  $\mu$  y varianza  $\sigma^2$ .
- Luego:  $\frac{(n-1)S^2}{\sigma^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - \bar{Y})^2$  tiene una distribución  $\chi^2$  con **n-1 grados de libertad**.
- Además,  $\bar{Y}$  y  $S^2$  son variables aleatorias independientes.

## Extensiones

- Sea  $Z$  una variable aleatoria **Normal Estándar** y sea  $W$  una variable aleatoria  **$\chi^2$  con  $\nu$  grados de libertad**. Luego, si  $Z$  y  $W$  son independientes, se tiene que  $T = \frac{Z}{\sqrt{\frac{W}{\nu}}}$  sigue una distribución **t con  $\nu$  grados de libertad**.



## Extensiones

- A partir de lo anterior, si  $Y_1, \dots, Y_n$  es una muestra aleatoria de tamaño  $n$  de una **distribución Normal** con una media  $\mu$  y varianza  $\sigma^2$ , se sabe que  $Z = \frac{\sqrt{n}(\bar{Y} - \mu)}{\sigma}$  sigue una **distribución Normal Estándar**.
- También sabemos que  $W = \frac{(n-1)S^2}{\sigma^2}$  tiene distribución  **$\chi^2$  con  $\nu = n - 1$  grados de libertad**.
- Además,  $Z$  y  $W$  son independientes porque  $\bar{Y}$  y  $S^2$  son independientes.
- Esto forma parte del Lema de Fisher.
- Entonces,  $T = \frac{Z}{\sqrt{\frac{W}{\nu}}} = \frac{\sqrt{n}(\bar{Y} - \mu)}{S}$  sigue una distribución **t con  $\nu = n - 1$  grados de libertad**.



# DISTRIBUCIONES EN MUESTRAS

- La distribución  $t$  es simétrica con respecto al 0, al igual que la distribución Normal Estándar, pero se dice que tiene colas más pesadas.
- A continuación se muestra un set de datos ( $n = 15000$ ) generados a partir de una distribución Normal Estándar y de una distribución  $t$  con  $\nu = 10$  grados de libertad.



## Distribución F

- Sean  $W_1$  y  $W_2$  variables aleatorias independientes, distribuidas según  $\chi^2$  con  $\nu_1$  y  $\nu_2$  grados de libertad respectivamente. Luego:  $F = \frac{W_1/\nu_1}{W_2/\nu_2}$  sigue una distribución F con  $(\nu_1, \nu_2)$  grados de libertad. (También se habla de grados de libertad de numerador y denominador).

## Distribución F

- A partir de lo anterior, consideremos **dos** muestras provenientes de **dos** poblaciones independientes. Se sabe que  $W_1 = \frac{(n_1 - 1)S_1^2}{\sigma_1^2}$  y  $W_2 = \frac{(n_2 - 1)S_2^2}{\sigma_2^2}$  tienen distribuciones  $\chi^2$  independientes con  $\nu_1 = n_1 - 1$  y  $\nu_2 = n_2 - 1$  grados de libertad, respectivamente ( $n_1$  y  $n_2$  son los tamaños de cada muestra).
- Entonces,  $F = \frac{W_1/\nu_1}{W_2/\nu_2} = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}$  sigue una distribución **F con  $(\nu_1 - 1, \nu_2 - 1)$  grados de libertad.**
- Este estadístico será empleado para decidir pruebas de hipótesis relacionadas con varianzas.

### Distribución Normal $N(0, 1)$




FIGURE 9.3

### Distribución $\chi^2$





FIGURE 9.7

Fuente: *Introductory Probability and Statistical Applications*. Meyer, Paul L.


## Distribución Normal $N(0, 1)$ vs t-Student

FIGURA 7.3  
Comparación  
de las funciones de  
densidad normal  
estándar y t



## Distribución F

FIGURA 7.4  
Una típica función  
de densidad de  
probabilidad F



Fuente: Estadística Matemática con Aplicaciones. Wackerly, Mendenhall, Scheaffer.