

# Análisis de Correspondencias (AC)

Hamdi Raïssi

IES PUCV

hamdi.raïssi@pucv.cl

# Objetivos de esta parte

## Objetivos :

- a- Repaso del test de independencia del  $\chi^2$ .
- b- Representar y comprender la estructura de dependencia entre variables cualitativas.

# Los datos.

Tenemos dos variables cualitativas  $X$  y  $Y$ . Podemos representar las juntos en un cuadro de contingencia :

$X \backslash Y$	$B_1$	$\dots$	$B_j$	$\dots$	$B_y$	Total
$A_1$			$n_{1j}$			
$\vdots$			$\vdots$			
$A_i$	$\dots$	$\dots$	$n_{ij}$	$\dots$	$\dots$	$n_{i.}$
$\vdots$			$\vdots$			
$A_x$			$\vdots$			
Total			$n_{.j}$			$n$

# probabilidades empíricas.

- $n_{ij}$  : número de individuos con las modalidades  $A_i$  y  $B_j$ .
- $n_{ij}/n$  : frecuencia de  $A_i \cap B_j$  o estimación de  $P(A_i \cap B_j)$ .
- Si  $X$  y  $Y$  son independientes,  $n_{i.}n_{.j}/n^2$  es también una estimación de  $P(A_i \cap B_j) = P(A_i)P(B_j)$
- $n_{ij}/n_{i.}$  y  $n_{ij}/n_{.j}$  nos dan las **distribuciones condicionales** (empíricas).
- Las últimas columna y fila (*dividas por  $n$* ) son las **distribuciones marginales** (empíricas).

# Test de independencia del $\chi^2$ .

- La idea del test  $\chi^2$  : comparar  $n_{ij}$  con  $n_{i.}n_{.j}/n$ .
- Se puede mostrar que la estadística

$$\chi_{cal}^2 = \sum_{i=1}^x \sum_{j=1}^y \frac{(n_{ij} - n_{i.}n_{.j}/n)^2}{n_{i.}n_{.j}/n},$$

sigue una ley  $\chi^2_{(x-1)(y-1)}$ .

- En R : `chisq.test(cuadro.contingencia)`.
- Considerar los bases de datos UCBAdmissions, Titanic y HairEyeColor.

# Test de independencia del $\chi^2$ .

`library(datasets)`

- `chisq.test(HairEyeColor[,2])` : test de independencia de colores de pelos y ojos de las mujeres (poner 1 para los hombres).
- `chisq.test(UCBAdmissions[,6])` : test de independencia para el "Dept F" de la Universidad en termino de genero y rechazo/aceptación (poner 1,2,3,4,5 por los otros Dept).
- `chisq.test(Titanic[,2,2])` : test de independencia entre genero y clase/tripulación de los adultos sobrevivientes del Titanic (poner 1 por los niños en la tercera coordenada y 1 por los fallecidos en la cuarta coordenada).

Manipulando la base de datos se podría hacer un test de independencia fallecido/sobreviviente con clases y tripulación.

# Test de independencia del $\chi^2$ y análisis de correspondencias.

- Es una conclusión general, sin embargo queremos tener una imagen más precisa de las dependencias.
- Vamos a presentar el análisis de correspondencias (AC) por filas.
- La presentación es la misma por columnas, y se puede mostrar que las columnas y filas tienen un rol simétrico.

# Análisis de correspondencias : intuición matemática.

- Si tenemos independencia :

$$\frac{P(A_i \cap B_j)}{P(A_i)} = P(B_j/A_i) = P(B_j).$$

- En practica (*"multiplicando" por n abajo y arriba la ecuación anterior a la izquierda*) :

$$\frac{n_{ij}}{n_{i.}} = \frac{n_{.j}}{n},$$

o de manera *approximativa* en general...



# Análisis de correspondencias : intuición matemática.

- Para cada modalidad de  $X$ , podemos definir los perfiles filas (es un vector en  $R^y$ ) :

$$P_{A_i} = (n_{i1}/n_{i.}, n_{i2}/n_{i.}, \dots, n_{iy}/n_{i.})'.$$

- En caso de independencia tenemos **de acuerdo a las ecuaciones de la diapositiva anterior** :

$$P_{A_1} = P_{A_2} = \dots = P_{A_x} = G_X,$$

o de manera aproximativa en general con

$$G_X = (n_{.1}/n, n_{.2}/n, \dots, n_{.y}/n)'$$

# Los perfiles :

$X \backslash Y$	$B_1$	...	$B_j$	...	$B_y$	Total
$P_{A_1}$			$n_{1j}/n_{1.}$			1
$\vdots$			$\vdots$			1
$P_{A_i}$	...	...	$n_{ij}/n_{i.}$	...	...	1
$\vdots$			$\vdots$			1
$P_{A_x}$			$n_{xj}/n_{x.}$			1
$G_X$			$n_{.j}/n$			1

Tenemos  $x$  puntos  $(P_{A_1}, \dots, P_{A_x})$  que se ubican en  $\mathbb{R}^y$ .

# Los perfiles :

- Todas las filas **deben ser iguales en caso de independencia** (o de manera aproximativa).
- La manera de como los puntos se descartan entre ellos nos da **información sobre la dependencia**.
- A muchas veces tenemos muchas modalidades, los perfiles son en  $R^y$ , con  $y \gg 2$ .
- Difícil de comprender como son ubicados los puntos en  $R^y$ ....

# Los perfiles :

- Vamos a proyectar la nube de puntos  $P_{A_1}, P_{A_2}, \dots, P_{A_x}$  de  $R^y$  sobre  $R^2$  (en general).
- Minizando las distorciones del nube de puntos.
- Por eso ocupamos la **distancia del chi-cuadrado** entre dos perfiles :

$$d_{\chi^2}^2(i, i') = \sum_{j=1}^y \frac{n}{n_{.j}} \left( \frac{n_{ij}}{n_{i.}} - \frac{n_{i'j}}{n_{i'.}} \right)^2.$$

# Los perfiles :

- El termino del chi-cuadrado viene del hecho que la inercia (o varianza, o suma de las distancias al centro de gravedad) del nube de puntos es la estadística del test de independencia del  $\chi^2$ .
- Cuando dos perfiles parecen similares (que sean columnas o filas) se justifica la fusión de las columnas.
- Utilizando  $d_{\chi^2}^2(i, i')$ , si se juntan dos perfiles columnas, la distancia entre los perfiles filas no cambian.

# Los perfiles :

- Se optimiza la variabilidad de los nubes proyectados.
- Se obtiene vectores propios y valores propios tal que ACP
- Sin embargo los valores propios son entre 0 y 1.

# Los perfiles :

- Hacer el AC de la base de datos HairEyeColor, hombre o mujeres (o los dos) como quieren...
- Se destaca la oposición Blue/Blond  $\longleftrightarrow$  Black, Brown/Brown
- Las otras modalidades no parecen bien representada en el AC.
- No hay un punto cerca el centro de gravedad (o sea modalidades "promedio" de la población). Hay muchos contrastes.

# Como el AC describe la dependencia :

## Comentarios del estudio :

- Más nos descartamos del centro de gravedad, más hay dependencia.
- Identificamos los perfiles que se alejan más del centro de gravedad.
- De la diferencias entre puntos obtenemos la interpretación de los componentes principales.



# Como el AC describe la dependencia :

Estadística  $V$  (de Cramer) :

- Se puede mostrar que la inercia total  $\chi_{cal}^2$  (la estadística del test de independencia) es tal que

$$\frac{\chi_{cal}^2}{n} \leq \min(x - 1, y - 1)$$

- Definimos :

$$V = \frac{\chi_{cal}^2}{n \min(x - 1, y - 1)}$$

- Estadística  $V$  (de Cramer) : si es cerca 0 estamos cerca la independencia. Si es cerca 1 estamos con relaciones entre variables fuerte.